B.F.3

B.F.3 Übung zu Diagnostik/Testtheorie

Gütekriterien

Bißantz, S., Kuch, N. & Gürtler, R.-M.

Rheinland-Pfälzische Technische Universität Kaiserslautern-Landau

Semesterübersicht

Nr.	Datum	Thema
1	ab 20.10.	Einführung & Rechenkompetenzen
2	ab 27.10.	Rechenkompetenzen
3	ab 03.11.	Gütekriterien
4	ab 10.11.	Schritte der Testkonstruktion & Erstellung eines Testentwurfs
		Lektürewoche
5	ab 24.11.	Klassische Testtheorie
6	ab 01.12.	*Diagnostische Rechenkompetenzen I*
7	ab 08.12.	*Item-Response-Theorie*
8	ab 15.12.	Exploratorische Faktorenanalyse I
		Weihnachtsferien
9	ab 05.01.	*Exploratorische Faktorenanalyse II*
10	ab 12.01.	Itemanalyse I
11	ab 19.01.	Itemanalyse II, Itemselektion und Testrevision
12	ab 26.01.	*Diagnostische Rechenkompetenzen II*
13	ab 02.02.	Gütekriterien II

Überblick

Qualitätsanforderungen an Tests

- Hauptgütekriterien
- Nebengütekriterien

Hauptgütekriterien

- Objektivität
- Reliabilität
- Validität
- Skalierung

Nebengütekriterien

- Normierung
- Ökonomie
- Nützlichkeit
- Zumutbarkeit
- Unverfälschbarkeit
- Fairness

Hauptgütekriterien

Objektivität

Ein Test ist objektiv, wenn die Durchführung und Auswertung des Tests sowie die Interpretation des Testergebnisses unabhängig von der Testleitung sind (Moosbrugger & Kelava, 2020, Kapitel 2).

- Durchführungsobjektivität
- Auswertungsobjektivität
- Interpretationsobjektivität

Durchführungsobjektivität

Standardisierung der Durchführungsbedingungen, z. B.

- Instruktion
- Zeitbegrenzung

Auswertungsobjektivität

- Auswertung mit Schablonen oder Computern
- Bei Ratingskalen und Multiple Choice in der Regel leicht zu erreichen
- Bei offenen Antwortformaten: Festlegung exakter Auswertungsregeln
- Lässt sich angeben als Grad der Übereinstimmung zwischen Testauswerter:innen

Interpretationsobjektivität

Liegt vor, wenn verschiedene Testauswerter:innen bei identischen Testergebnissen dieselben Schlussfolgerungen ziehen

- Normtabellen zur Einordnung der Testperson im Vergleich zu relevanten Bezugsgruppen

Reliabilität

Die Reliabilität gibt den Grad der Messgenauigkeit eines Messwerts an (Stichwort: Messfehler). Reliabilitätskoeffizienten haben einen Wertebereich von 0 bis 1.

Verfahren zur Bestimmung der Reliabilität

- Retest-Reliabilität
- Paralleltest-Reliabilität
- Testhalbierungs-Reliabilität
- Interne Konsistenz

Retest-Reliabilität

- Test wird zu zwei verschiedenen Zeitpunkten durchgeführt
- Korrelation der beiden Testergebnisse
- Probleme: Korrelation kann in Abhängigkeit vom Zeitintervall variieren (Übungs- und Erinnerungseffekte, Merkmalsveränderungen)

Paralleltest-Reliabilität

- Korrelation der Testwerte aus „parallelen“ Testformen, die dasselbe Konstrukt erfassen und aus inhaltlich möglichst ähnlichen Items bestehen („Itemzwillinge“)
- Probleme: schwierig, parallele Testformen herzustellen; Verzerrungseffekte durch Wiederholungsmessung

Testhalbierungs-Reliabilität

- Test wird in möglichst gleiche Hälften geteilt
- Korrelation der Testhälften
- Korrekturfaktor für die Testlänge → aufgewertete Testhalbierungs-Reliabilität

Interne Konsistenz

- Jedes Item wird als eigenständiger Testteil angesehen
- Korrelation der Testteile (Items) unter Berücksichtigung der Testlänge

Validität

Die Validität gibt an, ob der Test wirklich das misst, was er zu messen beansprucht.

- Inhaltsvalidität
- Kriteriumsvalidität
- Konstruktvalidität

Inhaltsvalidität

Ausmaß, in dem ein Test oder ein Testitem das zu messende Merkmal repräsentativ erfasst

- Repräsentationsschluss: Testitems als repräsentative Stichprobe aus dem „Universum“ von Items, die das interessierende Merkmal abbilden
- Bestimmung aufgrund logischer und fachlicher Überlegungen (z. B. Befragung von Expert:innen)
- Eng verbunden mit der Augenscheinvalidität eines Tests

Kriteriumsvalidität

Zusammenhang des Testwerts mit Kriterien: Vom Verhalten innerhalb der Testsituation (Testwert) wird auf Verhalten außerhalb der Testsituation (Kriterium) geschlossen.

- Vorhersagevalidität
- Übereinstimmungsvalidität
- Retrospektive Validität
- Inkrementelle Validität

Vorhersage- und Übereinstimmungsvalidität

Vorhersagevalidität

- Korrelation mit einem zeitlich später erhobenen Kriterium
- Z. B. wird die Leistung im Intelligenztest zu Beginn des Studiums mit der Bachelor-Abschlussnote korreliert

Übereinstimmungsvalidität

- Korrelation mit einem zeitgleich erhobenen Kriterium
- Z. B. wird die Leistung im Konzentrationstest mit dem Erfolg in der Führerscheinprüfung korreliert

Retrospektive und inkrementelle Validität

Retrospektive Validität

- Korrelation mit einem zeitlich vorher erhobenen Kriterium
- Z. B. wird die Leistung im Intelligenztest während des Studiums mit der Abiturnote korreliert

Inkrementelle Validität

- Beitrag eines Tests zur Verbesserung der Vorhersage eines Kriteriums
- Z. B. Gewissenhaftigkeit zur Vorhersage des Berufserfolgs, inkrementell zur Leistung im Intelligenztest

Konstruktvalidität

Liegt vor, wenn die Schlussfolgerungen, die aufgrund des Testwerts über das zugrunde liegende Konstrukt gezogen werden, wissenschaftlich fundiert sind

- Konvergente Validität: Korrelation mit Tests, die das gleiche oder ein ähnliches Konstrukt erfassen → Erwartung hoher Zusammenhänge
- Diskriminante Validität: Korrelation mit Tests, die ein anderes Konstrukt erfassen → Erwartung niedriger Zusammenhänge
- Faktorielle Validität: Prüfung der Struktur mit Verfahren der Faktorenanalyse (exploratorisch und konfirmatorisch) und der Item-Response-Theorie

Skalierung

Die Testwerte, die laut Verrechnungsregel resultieren, bilden die empirischen Merkmalsrelationen adäquat ab.

- Höhere Merkmalsausprägung → höherer Testwert
- Abhängig vom Skalenniveau des Tests
  - Ungeordnete Kategorien (z. B. Geschlecht, Wohnort)
  - Geordnete Kategorien (z. B. Leistungsklasse: unsportlich, Freizeitsport, Hochleistungssport)
  - Beurteilung der Größe der Merkmalsunterschiede (z. B. Gewicht, Körpergröße, Intelligenz, Narzissmus)

Nebengütekriterien

Normierung

Einordnung des individuellen Testwerts in eine Referenzgruppe

- Geeignete Normstichprobe (auch: Eichstichprobe)
  - Ähnlichkeit zur Testperson in relevanten Merkmalen (z. B. Alter, Geschlecht, Schulbildung)
  - Möglichst groß und repräsentativ
- Relativierung an der Normstichprobe
  - Prozentrangnormen (nicht verteilungsgebunden)
  - Standardnormen, z. B. *z*-, IQ-, *T*-, Stanine-Werte (verteilungsgebunden)
- DIN 33430: Normen alle acht Jahre überprüfen, ggf. neu normieren
- Nicht erforderlich bei kriteriumsorientiertem Testen (z. B. Kompetenzstufen)

Ökonomie

Geringe Kosten (Zeit, Geld, ...) gemessen am diagnostischen Erkenntnisgewinn

- Oft nur im Vergleich mit ähnlichen Tests bestimmbar
- Hohe Ökonomie darf nicht zulasten anderer Gütekriterien gehen (v. a. Validität)

Nützlichkeit

Praktische Relevanz und Nutzen der getroffenen Entscheidungen

- Erfasst der Test ein praktisch relevantes Merkmal oder sagt er es vorher?
- Mehr Nutzen als Schaden der auf Grundlage des Tests getroffenen Entscheidungen?
- Kein anderer Test für das Merkmal, der die übrigen Gütekriterien genauso gut erfüllt?

Zumutbarkeit

Belastung der Testperson

- Keine übermäßige Belastung in zeitlicher, psychischer und körperlicher Hinsicht
- Relativ zu dem aus der Anwendung resultierenden Nutzen

Unverfälschbarkeit

Ist „Faking“ möglich?

- Die Testperson kann die Ausprägung ihrer Testwerte nicht durch gezieltes Testverhalten steuern oder verzerren (meist eine Frage des Grades)
- Bedrohung: hohe Durchschaubarkeit, daher Verzerrung durch sozial erwünschtes Antwortverhalten möglich
  - Beispiel: „Ich achte auf die Bedürfnisse anderer.“
- Weniger anfällig: Leistungstests oder „objektive Tests“

Fairness

Keine systematische Benachteiligung bestimmter Personen aufgrund ihrer Zugehörigkeit zu ethnischen, soziokulturellen oder geschlechtsspezifischen Gruppen

- Kann Inhalt und Durchführung betreffen
- Z. B. Unfairness durch Itembias: Aufgaben sind systematisch unterschiedlich schwierig für unterschiedliche Gruppen
- V. a. wenn der Testwert neben dem zu erfassenden Merkmal systematisch durch andere, irrelevante Merkmale beeinflusst wird

Interpretation

Interpretation der Gütekriterien

- Gütekriterien sind keine Eigenschaft des Tests
  - Nicht der Test an sich ist valide, sondern die Schlussfolgerungen aus den Testergebnissen
- Gütekriterien gelten genau genommen für Testkennwerte in bestimmten Stichproben
  - Z. B. „Cronbachs α für die Summenscores der Big Five betrug 0.93 für Neurotizismus, 0.89 für Extraversion, …“

Übungsheft

Übungen

Übungen zu diesem Thema: Übungsheft, Kapitel 3

Literaturverzeichnis

Literatur

Moosbrugger, H., & Kelava, A. (Hrsg.). (2020). *Testtheorie und Fragebogenkonstruktion* (3. Aufl.). Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-662-61532-4